

Introduction à la statistique

Introduction

La statistique est la science de la collecte, de l'organisation et de l'interprétation des faits numériques, que nous appelons données.

Nous sommes bombardés de données dans notre vie quotidienne. On cite : les ventes au box-office de films, les derniers sondages sur la popularité d'un président et la température moyenne élevée pour la date d'aujourd'hui, les statistiques sur l'économie.

Introduction

Toutes les parties dans les débats publics sur l'économie, l'éducation et la politique sociale argumentent à partir des données. Une connaissance des statistiques permet de séparer le sens du non-sens dans ce flot de données,

Introduction

Données

Avant la présentation et l'interprétation de renseignements, il y a la collecte et le classement des données.

«Autant les arbres constituent la matière première du papier, autant, les données sont la matière brute d'où naît l'information. »

As far as the laws of mathematics refer to reality they are not certain, and as far as they are certain they do not refer to reality.

ALBERT EINSTEIN

Introduction

Information

L'information pourrait être définie comme des données qui ont été consignées, classées, organisées, raccordées ou interprétées dans un cadre qui en dégage le sens.

L'information, comme les données, peut prendre différentes formes.

Voici quelques exemples du genre d'information qu'on peut tirer des données.

- ✓ le nombre de personnes dans un groupe selon la catégorie de poids;
- ✓ le nombre total de ménages qui n'ont pas loué de films au cours du dernier mois;
- ✓ le nombre de jours pendant la semaine où la température était supérieure à 20 degrés Celsius.

Introduction

Statistiques et statistique

Les statistiques sont utilisées couramment pour la présentation de l'information. Le terme se réfère d'ordinaire à des données numériques mais il peut aussi faire référence à la science du traitement des données numériques.

Les statistiques visent avant tout à fournir des renseignements utiles à l'aide de chiffres. La statistique pourrait donc être définie comme de l'information qu'on peut obtenir à partir d'opérations mathématiques sur des données numériques.

La statistique joue un rôle crucial en data science pour plusieurs raisons :

- ☐ **Compréhension des données**
- ☐ **Inférence Statistique**
- ☐ **Tests d'Hypothèses**
- ☐ **Modélisation Statistique**
- ☐ **Probabilité**
- ☐ **Validation de Modèles**

Introduction

Données	Information	Statistiques
20 kg à 25 kg	5 élèves dans la catégorie de 20 à 25 kg	Poids moyen = 22,5 kg
28 kg, 30 kg	15 élèves dans la catégorie de 26 à 30 kg	Poids médian = 28 kg

Exemple réel

Informations sollicitées

- Fréquentation des 10 magasins étudiés
- Fréquence d'achats des ménages dans les 10 magasins étudiés
- Importance relative attachée à chacun des 8 facteurs de choix d'une enseigne, à savoir:

qualité des produits, assortiment et variété des produits, politique de reprises et de retour, qualité de service du personnel prix prix, commodité du lieu, organisation du magasin et politique de crédit.

Définition de la statistique

- **Le mot "statistique" peut s'interpréter de deux façons :**

- **au pluriel :**

Les **statistiques** sont des faits classifiés concernant une catégorie particulière d'objets.

- Exemple : les statistiques relatives aux taux de chômage dans un pays, les statistiques sur les accidents automobiles durant une année, etc.

- **au singulier :**

La **statistique** est l'ensemble des méthodes scientifiques visant à collecter, à résumer, à organiser et à analyser des données numériques, de même qu'à tirer des conclusions valables et à prendre des décisions raisonnables sur la base de cette analyse.

La **statistique** désigne aussi une quantité particulière comme par exemple une moyenne, une variance, etc. que l'on peut calculer à partir d'un **échantillon**.


Les étapes de la statistique

- Une étude statistique comporte 4 étapes :

- ❖ *La collecte des données*
- ❖ *La statistique descriptive*
- ❖ *L'inférence statistique*
- ❖ *La décision statistique*


La collecte des données

- Consiste à rassembler de l'information qui est déjà disponible dans des documents pré-établis ou encore à recueillir des données originales.



La statistique descriptive


- Consiste en un traitement des données qui a pour but de présenter, de résumer et/ou de décrire les caractéristiques (moyenne, variance, proportion) essentielles qui se dissimulent dans une masse de données.



$$\text{Moyenne} : \sum_i \frac{x_i}{n}$$


L'inférence statistique

- Regroupe l'ensemble des méthodes (estimation, tests d'hypothèses, etc.) qui permettent de tirer des conclusions sur une population à partir d'une information partielle provenant d'un échantillon.



La décision statistique

- Regroupe un ensemble de techniques permettant de déterminer la meilleure action parmi un ensemble d'actions envisageables dans un contexte d'incertitude.



Terminologie

- **Population**

- c'est l'ensemble de tous les individus concernés lors de l'étude d'un sujet particulier. (N = taille de la population)

- **Échantillon**

- Toute partie ou sous-ensemble de la population (n = taille de l'échantillon)

- **Individus ou unité statistique**

- Chaque élément de la population ou de l'échantillon.

Terminologie

- Exemples (populations et échantillons):
 - Un médecin vérifie un nouveau médicament sur 100 patients atteints de leucémie, choisis au hasard.
 - Population : l'ensemble de tous les leucémiques identifiés.
 - Échantillon : les 100 patients sur lesquels le nouveau médicament est appliqué
 - La compagnie Lampaclaire Québec achète 10 000 ampoules électriques d'un fabricant qui affirme que ses ampoules ont une vie moyenne d'au moins 1 000 heures. La compagnie Lampaclaire Québec vérifie 15 ampoules et, suite à ces résultats, doit décider si elle garde ou non les 10 000 ampoules.
 - Population : l'ensemble des 10 000 ampoules achetées.
 - Échantillon : les 15 ampoules vérifiées.

Terminologie

- **Caractère ou variable statistique**

- C'est l'aspect particulier que l'on désire étudier.
 - Des caractéristiques physiques (taille, poids, couleurs des cheveux ou des yeux,...)
 - Des caractéristiques du personnel d'une entreprise (sexe, âge, état matrimonial, nombre d'enfants à charge, qualification, salaire, ...)
 - Etc.

- **Modalité**

- Ce sont les différentes possibilités que peut présenter un caractère.
 - Sexe : masculin ou féminin
 - Religion : christianisme, islam et judaïsme
 - État matrimonial : célibataire, marié, veuf et divorcé.
 - Âge : 1, 2, 3, ..., 99, ...
 - ...

Terminologie

- **Un caractère peut être :**
 - **Qualitatif** : si ses modalités ne s'expriment pas par un nombre.
 - Sexe, état matrimonial, ...
 - **Quantitatif** : si ses modalités sont numériques.
 - Salaire, âge, poids, ...
 - **Il y a deux types de caractères quantitatifs :**
 - **Discret** : lorsque les modalités de ce caractère ne peuvent prendre que des valeurs isolées (le plus souvent entières) (nombre d'enfants, nombre de chambres, ...)
 - **Continue** : lorsque les modalités de ce caractère sont susceptibles de prendre n'importe quelle valeur dans un intervalle donné (taille, poids, ...)

Terminologie

- **Série statistique**

- C'est l'ensemble des différentes données associées aux individus d'un échantillon ou d'une population.

- **Exemple (série statistique):**

	sexe	daten	annedu	salaire	salairered	expepre
1	m	02/03/52	15	\$57,000	\$27,000	144
2	m	05/23/58	16	\$40,200	\$18,750	36
3	f	07/26/29	12	\$21,450	\$12,000	381
4	f	04/15/47	8	\$21,900	\$13,200	190
5	m	02/09/55	15	\$45,000	\$21,000	138
6	m	08/22/58	15	\$32,100	\$13,500	67
7	m	04/26/56	15	\$36,000	\$18,750	114
8	f	05/06/66	12	\$21,900	\$9,750	0
9	f	01/23/46	15	\$27,900	\$12,750	115
10	f	02/13/46	12	\$24,000	\$13,500	244
11	f	02/07/50	16	\$30,300	\$16,500	143
12	m	01/11/66	8	\$28,350	\$12,000	26
13	m	07/17/60	15	\$27,750	\$14,250	34
14	f	02/26/49	15	\$35,100	\$16,800	137
15	m	08/29/62	12	\$27,300	\$13,500	66
16	m	11/17/64	12	\$40,800	\$15,000	24
17	m	07/18/62	15	\$46,000	\$14,250	48
18	m	03/20/56	16	\$103,750	\$27,510	70
19	m	08/19/62	12	\$42,300	\$14,250	103
20	f	01/23/40	12	\$26,250	\$11,550	48