

Chapitre 1

Organisation des données

- ▣ Introduction
- ▣ Tableaux statistiques
- ▣ Représentations graphiques

Introduction

L'analyse descriptive des données ou la statistique descriptive est un traitement de données qui offre des outils appropriés (Tableau, graphiques et mesures numériques) permettant de dégager l'information essentielle qui se dissimule dans une masse de données brutes.

Introduction

- Il existe trois types de traitements que nous pouvons effectuer sur une série statistique :
 - 1) La synthèse de la série à l'aide d'un **tableau statistique**
 - 2) Les **représentations graphiques** du caractère étudié
 - 3) Le calcul des **mesures caractéristiques**.

Tableaux statistiques

- Généralement, on retrouve trois types d'information dans un tableau statistique :
 - ❖ Distribution de fréquence n_i (effectif)
 - ❖ Distribution de fréquence relative f_i
 - ❖ Distribution de fréquence relative cumulée F_i

Tableaux statistiques

Notations

X : une variable statistique (ou un caractère)

X_i : modalités ou valeurs possibles prises par la variable statistique X

n_i : le nombre d'unités (fréquence) présentant la valeur X_i

n : le nombre total d'unités

$f_i = \frac{n_i}{n}$: la fréquence relative de X_i

Tableaux statistiques

- La distribution de **fréquence** d'une variable statistique X est une fonction qui, à chaque valeur x_i de la variable, fait correspondre sa fréquence n_i .
- La distribution de **fréquence relative** d'une variable statistique X est une fonction qui, à chaque valeur x_i de la variable, fait correspondre sa proportion $f_i = \frac{n_i}{n}$

Tableaux statistiques

La clinique médicale MD a fait une étude sur tous ses dossiers de varicelle recensée cette année et on y a notamment enregistré le nombre de frères et sœurs de 60 patients atteints de cette maladie contagieuse. On relève les données brutes suivantes :

Données									
2	1	3	0	6	0	1	2	3	1
3	0	2	0	4	1	0	4	0	2
1	1	3	2	3	3	2	1	1	1
0	1	2	4	1	2	2	7	3	2
0	1	1	2	5	5	3	4	3	0
1	2	2	3	0	1	2	0	2	2

Posons X = la variable statistique représentant le nombre de frères et sœurs de chacun des patients atteints de cette maladie contagieuse.

Tableaux statistiques

Fréquence, fréquence relative et fréquence relative cumulée :

Modalités	Fréquence	Fréquence relative (%)	Fréquence relative cumulée (%)
0	11	18.3	18.3
1	15	25	43.3
2	16	26.6	69.9
3	10	16.7	86.6
4	4	6.7	93.3
5	2	3.3	96.6
6	1	1.7	98.3
7	1	1.7	100
Total	60	100	

Tableaux statistiques


- Lorsque la variable est continue, ou que la variable peut prendre un grand nombre de valeurs différentes, même si celle-ci est une variable discrète, **il convient de regrouper ces valeurs en classes.**
- À **chaque classe** on fait correspondre une fréquence ou une fréquence relative, et l'on obtient alors une distribution de fréquence ou de fréquence relative **pour valeurs groupées.**
- Pour construire une distribution de fréquence, de fréquence relative ou de fréquence relative cumulée pour valeurs groupées on doit procéder de la manière suivante :
 1. **Déterminer le nombre de classes**
 2. **Déterminer l'amplitude des classes**
 3. **Déterminer les différentes classes**

Tableaux statistiques

1. Déterminer le nombre de classes :

1) $N_C = 1 + 3.3 \log(n)$ (règle de Sturges)

2) $N_C = \sqrt{n}$



Nombre d'observations
dans la série statistique

Tableaux statistiques

2. Calculer l'amplitude des classes :

1) D'une façon plus ou moins arbitraire

2) En utilisant l'étendue

- $E = x_{\max} - x_{\min} =$ (Plus grande valeur de la série statistique – Plus petite valeur de la série statistique)

- $A_C = \frac{E}{N_C}$

Des classes d'amplitudes égales

Tableaux statistiques

3. Déterminer les différentes classes :

$$x_{\min} \leq Classe_1 < x_{\min} + A_c$$

$$x_{\min} + A_c \leq Classe_2 < x_{\min} + 2A_c$$

⋮

$$x_{\min} + (k-1)A_c \leq Classe_k < x_{\min} + kA_c$$

⋮

$$x_{\min} + (N_c - 1)A_c \leq Classe_{N_c} < x_{\min} + N_c A_c$$

Tableaux statistiques

Pour les trois dernières années, le débit mensuel moyen d'une rivière, exprimé en milliers de mètres cubes par seconde, a été le suivant :

Données								
0.22	0.09	0.08	0.10	1.05	0.36	0.18	0.15	0.15
0.22	0.11	0.09	0.09	0.19	0.68	0.78	0.42	0.15
0.66	0.39	0.34	0.19	0.15	0.08	0.08	0.37	0.67
0.23	0.16	0.35	0.34	0.21	0.11	0.32	0.22	0.36

Variable continue

Posons X = la variable statistique représentant le débit mensuel moyen d'une rivière.

Tableaux statistiques

(1) Nombre de classes :

$$N_C = 1 + 3.3 \log(36) = 6.1358 \text{ classes}$$

$$N_C = \sqrt{36} = 6 \text{ classes}$$

(2) L'amplitude des classes :

$$E = 1.05 - 0.08 = 0.97$$

$$A_C = \frac{0.97}{6} = 0.1617 \approx 0.17$$

(3) Détermination des classes :



Débit D

(en milliers de m³)

$$0.08 \leq \text{Classe}_1 < 0.25$$

$$0.25 \leq \text{Classe}_2 < 0.42$$

$$0.42 \leq \text{Classe}_3 < 0.59$$

$$0.59 \leq \text{Classe}_4 < 0.76$$

$$0.76 \leq \text{Classe}_5 < 0.93$$

$$0.93 \leq \text{Classe}_6 < 1.10$$

Tableaux statistiques

(1) Nombre de classes :

$$N_C = 1 + 3.3 \text{Log}(36) = 6.1358 \text{ classes}$$

$$N_C = \sqrt{36} = 6 \text{ classes}$$

(2) L'amplitude des classes :

$$E = 1.05 - 0.08 = 0.97$$

$$A_C = \frac{0.97}{6} = 0.1617 \approx 0.17$$

(3) Détermination des classes :



Débit D

(en milliers de m³)

$$0.08 \leq \text{Classe}_1 < 0.25$$

$$0.25 \leq \text{Classe}_2 < 0.42$$

$$0.42 \leq \text{Classe}_3 < 0.59$$

$$0.59 \leq \text{Classe}_4 < 0.76$$

$$0.76 \leq \text{Classe}_5 < 0.93$$

$$0.93 \leq \text{Classe}_6 < 1.10$$

Tableaux statistiques

Distribution de fréquence, de fréquence relative et de fréquence relative cumulée :

Classes	Centre de la classe	Fréquence	Fréquence relative (%)	Fréquence relative cumulée (%)
$0.08 \leq Classe_1 < 0.25$	0.165	22	61.1	61.1
$0.25 \leq Classe_2 < 0.42$	0.335	8	22.2	83.3
$0.42 \leq Classe_3 < 0.59$	0.505	1	2.8	86.1
$0.59 \leq Classe_4 < 0.76$	0.675	3	8.3	94.4
$0.76 \leq Classe_5 < 0.93$	0.845	1	2.8	97.2
$0.93 \leq Classe_6 < 1.10$	1.015	1	2.8	100
		36 observations	100	

Représentations graphiques

Les représentations graphiques permettent de visualiser le résumé statistique produit par la distribution de fréquence, de fréquence relative et de fréquence relative cumulée (valeurs groupées ou non groupées).

- Les représentations graphiques les plus usuelles :

Valeurs non groupées

- Diagramme en bâton
 - Fréquence
 - Fréquence relative
- Diagramme en escalier
 - Fréquence relative cumulée

Valeurs groupées


- Histogramme
 - Fréquence
 - Fréquence relative
- Polygone
 - Fréquence
 - Fréquence relative
- Ogive
 - Fréquence relative cumulée

Représentations graphiques

Diagramme en bâton


- ❖ Construit pour des variables discrètes ayant peu de modalités
- ❖ Les bâtonnets sont séparés les uns des autres
- ❖ Les bâtonnets doivent avoir la même largeur

Exemple 1 : valeurs non groupées (fréquence)




Représentations graphiques

Exemple 1 : valeurs non groupées (fréquence relative)



Représentations graphiques

Exemple 1 : valeurs non groupées (fréquence relative cumulée)




Représentations graphiques

Histogramme


- ❖ Construit pour des variables continues ou des variables discrètes ayant un grand nombre de modalités
- ❖ Les bâtonnets ne sont pas séparés
- ❖ Les bâtonnets ne sont pas **nécessairement** de même largeur
- ❖ On doit indiquer le point milieu **ou** les bornes de chaque bâtonnet.

Exemple 2 : Histogramme de fréquence pour valeurs groupées




Représentations graphiques

Exemple 1 : Histogramme de fréquence relative pour valeurs groupées




Représentations graphiques

Exemple 1 : Polygone de fréquences pour valeurs groupées




Représentations graphiques

Exemple 1 : Polygone de fréquence relative pour valeurs groupées



Représentations graphiques

Exemple 1 : Ogive de fréquence relative cumulée pour valeurs groupées



Représentations graphiques (caractère qualitatif)

Exemple:

On a pris un échantillon de 50 achats de boissons non-alcoolisées achetées dans une grande surface, en notant par :

CC=Coca-Cola; S=Sprite; CL=Coke-Light;
P=Perrier; PC=Pepsi-Cola.

Représentations graphiques

On a obtenu les résultats suivants:

CC S PC CL CC CC PC CL CC CL CC CC CC CL
PC CC
CC P P S CC CL PC CL PC CC PC PC CC PC CC
CC PC
P PC PC S CC CC CC S P CL P PC CC PC S CC
CL

Alors ici la variable est X =Boisson non-alcoolisée, **(qualitative nominale)**.


Pour ordonner ces données, on dresse un tableau, dans la première colonne on énumère les cinq modalités de la variable, dans la seconde colonne on donne la **fréquence absolue** ou (effectif) (c'est-à-dire le nombre de fois que cette modalité se répète dans l'échantillon) et dans la troisième colonne, on donne la **fréquence relative**. :égale à sa fréquence absolue divisée par la taille de l'échantillon

Tableau des fréquences des boissons non-alcoolisées		
X=Boisson	Fréquences absolues	Fréquences relatives
CC	19	0,38
CL	8	0,16
PC	13	0,26
P	5	0,10
S	5	0,10
Total	n=50	1


- Le diagramme à barres (**tuyaux d'orgue**) (horizontales ou verticales) :

Où on met sur un axe les modalités de la variable et sur l'autre axe les fréquences absolues ou les fréquences relatives.

Tableau des fréquences des boissons non-alcoolisées



- Le deuxième graphique qu'on peut faire est le **diagramme à secteurs (ou circulaire)** qui est une sorte de tarte où chaque modalité occupe une partie qui reflète sa fréquence relative.



Exemple:

Lors d'une enquête de satisfaction de la clientèle, une compagnie de courtage a demandé à un échantillon de 60 clients d'indiquer leur degré de satisfaction vis-à-vis de leur conseiller financier, sur une échelle de 1 à 7, le 1 correspondant à <<pas du tout satisfait>> et le 7 correspondant à <<extrêmement satisfait>>. On a obtenu les résultats suivants :

5	7	6	6	7	5	5	7	3	6	7	7	6	6	6	5	5	6	7	7
6	6	4	4	7	6	7	6	7	6	5	7	5	7	6	4	7	5	7	6
6	5	3	7	7	6	6	6	6	5	5	6	6	7	7	5	6	6	6	6

Tableau des fréquences du degré de satisfaction des clients.		
Degré de satisfaction	Fréquences absolues	Fréquences relatives
1	0	0,0000
2	0	0,0000
3	2	0,0333
4	3	0,0500
5	12	0,2000
6	25	0,4167
7	18	0,3000
Total	n=60	1,0000

Degré de satisfaction des clients.

