



Analyse statistique Bivariée



Pour commencer

- La statistique bivariée est l'étude **des relations** entre deux variables, quantitatives ou qualitatives.
- La statistique bivariée fait partie de la statistique descriptive.



► 1. Deux variables quantitatives

- Soit deux caractères quantitatifs X et Y .
- On dit qu'il existe une **relation** entre X et Y si l'attribution des modalités de X et de Y ne se fait pas au hasard, c'est à dire si les valeurs de X **dépendent** des valeurs de Y ou si les valeurs de Y **dépendent** des valeurs de X .
- En d'autres termes, si Y dépend de X , on peut trouver une fonction f telle que : **$Y=f(X)$**



Représentation graphique


- La comparaison de deux variables quantitatives se fait en premier lieu graphiquement, en représentant l'ensemble des couples de valeurs sous forme d'un nuage de points.
- L'ensemble des points forme un nuage de points dont la forme permet de caractériser la relation à l'aide de trois critères :
 - intensité de la relation
 - forme de la relation
 - sens de la relation




Intensité de la corrélation




- **une relation est forte** si les valeurs prises par X sont proches aux valeurs prises par Y.
=> le nuage de point prend alors la forme d'une ligne ou d'une courbe dont les points s'écartent peu.
- **Une relation est faible** si les valeurs prises par X sont éloignées des valeurs prises par Y.
=> le nuage de point n'a pas la forme d'une ligne ou d'une courbe
- **Une relation est nulle** si les valeurs de X ne permettent d'avoir aucune information sur les valeurs de Y
=> le nuage de point a la forme d'un carré, d'un cercle, sans véritables lignes directrices.




► Sens de la corrélation




relation linéaire positive



relation linéaire négative



relation non-linéaire positive




relation non-linéaire négative




Illustration graphique



Dépendance linéaire positive



Dépendance linéaire négative




Liaison linéaire positive: X et Y évoluent dans le même sens, une augmentation de X entraîne une augmentation de Y, du même ordre quelle que soit la valeur de X. le nuage de point peut s'ajuster à une droite.

Liaison linéaire négative: X et Y évoluent en sens inverse.


► Illustration graphique



Dépendance non-linéaire monotone




Dépendance non-linéaire non monotone



Liaison monotone non-linéaire: si elle est strictement croissante ou strictement décroissante, c'est-à-dire si elle ne comporte pas de minima ou de maxima. Toutes les relations linéaires sont monotones.

Liaison non-linéaire non-monotone: Il y a une relation fonctionnelle entre X et Y . Mais la relation n'est pas monotone, Y peut augmenter ou diminuer selon la valeur de X.

► Illustration graphique



La valeur de X ne donne pas une indication sur la valeur de Y , et inversement.

X (ou Y) est constant quelle que soit la valeur de la seconde variable.



Calcul d'indicateur

- En plus d'une représentation graphique, on peut calculer certains indicateurs permettant de mesurer le degré d'association de deux variables quantitatives.
- Le calcul du **coefficient de corrélation** peut être effectué en utilisant deux méthodes:
 - **corrélation r de Pearson**
 - **coefficient de corrélation Spearman**

Coefficient de corrélation de Pearson

- Ce coefficient permet de détecter la présence ou l'absence d'une **relation linéaire** entre deux caractères quantitatifs.
- Pour calculer ce coefficient il faut tout d'abord calculer la covariance.

$$cov(X, Y) = \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})(Y_i - \bar{Y}) = \frac{1}{N} \sum_{i=1}^N X_i Y_i - \bar{X} \bar{Y}$$

Le coefficient de Pearson est alors:


$$r(X, Y) = \frac{cov(X, Y)}{\sigma_X \sigma_Y}$$

Avec σ_X est l'écart type de la variable X (respectivement σ_Y)

► Interprétation



- Le coefficient de Pearson varie entre -1 et +1. Son interprétation est la suivante :
 - si r est proche de 0, il n'y a pas de relation linéaire entre X et Y
 - si r est proche de -1, il existe une forte relation linéaire négative entre X et Y.
 - si r est proche de 1, il existe une forte relation linéaire positive entre X et Y
- Le **signe** de r indique le sens de la relation tandis que la valeur absolue de r indique l'**intensité** de la relation.



► Limites du coefficient de Pearson



- Le coefficient de Pearson n'est applicable que pour mesurer la relation entre deux variables X et Y ayant **une distribution normale** et ne comportant pas de **valeur exceptionnelles**.
- L'absence d'une relation linéaire ne signifie pas l'absence de toute relation entre les deux caractères étudiés.



Le coefficient de corrélation de Spearman(de rang)



- Le coefficient de Spearman est très utile lorsque l'analyse du nuage de point révèle une forme curviligne dans une relation qui semble mal s'ajuster à une droite.
- On notera également qu'il est préférable au coefficient de Pearson lorsque les distributions X et Y sont dissymétriques et/ou comportent des valeurs exceptionnelles.
- Il se calcul comme suit:

$$\rho(X, Y) = 1 - \frac{6 \sum_{i=1}^N (r(X_i) - r(Y_i))^2}{N^3 - N}$$

- Son interprétation est la même que celui de Pearson.



Test de corrélation

- **Hypothèses du test:**

$H_0: r = 0$ absence de liaison entre X et Y .

H_1 bilatéral: $r \neq 0$ liaison entre X et Y .

H_1 unilatéral: $r > 0$ liaison positive entre X et Y ou $r < 0$ liaison négative entre X et Y .

- **La statistique du test:**

$$t_{ddl=n-2} = \frac{|r - 0|}{\sigma_r} \sim t_{n-2}$$

Avec $\sigma_r = \frac{\sqrt{n-2}}{r}$ et r est le coefficient de Pearson ou de Spearman



• Règles de décision et conclusion du test:

Si H_1 bilatérale : valeur théorique critique $t_{(ddl ; \alpha = 5\%)}$

$t_{\text{obs}} < t_{\text{ddl} ; \alpha = 5\%}$: acceptation de H_0 d'où absence de liaison significative entre X et Y.

$t_{\text{obs}} \geq t_{\text{ddl} ; \alpha = 5\%}$: rejet de H_0 d'où liaison significative entre X et Y.

Si H_1 unilatérale : valeur théorique critique $t_{ddl ; \alpha = 10\%}$

$t_{\text{obs}} < t_{\text{ddl} ; \alpha = 10\%}$: acceptation de H_0 d'où absence de liaison significative entre X et Y

$t_{\text{obs}} \geq t_{\text{ddl} ; \alpha = 10\%}$: rejet de H_0 d'où liaison positive ou négative significative entre X et Y





Conditions d'application des Tests de corrélation



- Le test de corrélation de Spearman est un test dit robuste car il ne dépend pas de la distribution des données.
- Le test de corrélation de **Pearson** ne s'applique pas que lorsque les variables suivent une **loi normale** et de variances égales.



2. Deux variables qualitatives



- Pour tester l'existence d'un lien entre les modalités de deux variable qualitatives:
 - On utilise de test de **CHI-2**.
 - Une représentation graphique.

► Tableau de contingence



- Pour étudier la relation entre deux variables qualitatives, on construit d'abord un tableau appelé table de contingence ou tableau croisé.

		Variable Y						
		y_1	y_2	...	y_j	...	y_m	Total
Variable X	x_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1m}	$n_{1.}$
	x_2	n_{21}	n_{22}	...	n_{2j}	...	n_{2m}	$n_{2.}$
	$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$	$\vdots$
	x_i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{im}	$n_{i.}$
	$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$	$\vdots$
	x_l	n_{l1}	n_{l2}	...	n_{lj}	...	n_{lm}	$n_{l.}$
Total		$n_{.1}$	$n_{.2}$	...	$n_{.j}$	...	$n_{.m}$	n

Tableau de contingence

n_{ij} : effectif joint de la modalité x_i et de la modalité y_i

n_i : effectif marginal de la modalité x_i

n_j : effectif marginal de la modalité y_i

n : taille de l'échantillon

► Tableau d'effectifs corrigés



- L'effectif corrigé se calcul ainsi:

$$n_{ij}^* = \frac{n_i n_j}{n}$$



		Variable Y						
		y ₁	y ₂	...	y _j	...	y _m	Total
Variable X	x ₁	n_{11}^*	n_{12}^*	...	n_{1j}^*	...	n_{1m}^*	$n_{1.}$
	x ₂	n_{21}^*	n_{22}^*	...	n_{2j}^*	...	n_{2m}^*	$n_{2.}$
	⋮	⋮	⋮	...	⋮	...	⋮	⋮
	x _i	n_{i1}^*	n_{i2}^*	...	n_{ij}^*	...	n_{im}^*	$n_{i.}$
	⋮	⋮	⋮	...	⋮	...	⋮	⋮
	x _l	n_{l1}^*	n_{l2}^*	...	n_{lj}^*	...	n_{lm}^*	$n_{l.}$
Total		$n_{.1}$	$n_{.2}$	...	$n_{.j}$	...	$n_{.m}$	n

Tableau d'effectifs corrigés

► Test de Khi-deux



Hypothèses du test:

H_0 : Les variables X et Y sont indépendantes.

H_1 : Il existe une liaison entre Les variables X et Y

Statistique du test:

Sous H_0 : $\chi^2 = \sum_{i=1}^l \sum_{j=1}^m \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} \sim \chi_{(l-1)(m-1)}^2$

Règle de décision:

Si la valeur de la statistique de test χ^2 est **inférieure** à la valeur seuil $\chi_{(l-1)(m-1)}^2$ alors on accepte l'hypothèse nulle.

Si la valeur de la statistique de test χ^2 est **supérieure** à la valeur seuil $\chi_{(l-1)(m-1)}^2$ alors on rejette l'hypothèse nulle.

Exemple:



Exposition	Etat du système immunitaire		Total
	I^-	I^+	
Exposé	135	120	255
Non exposé	150	195	345
Total	285	315	600



Exposition	Etat du système immunitaire		Total
	I^-	I^+	
Exposé	121.1	133.9	255
Non exposé	163.9	181.1	345
Total	285	315	600

Croisement entre l'exposition au produit chimique et l'état du système immunitaire

Tableau de contingence théorique

$$\text{Sous } H_0: \chi^2 = \sum_{i=1}^l \sum_{j=1}^m \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} \sim \chi_{(2-1)(2-1)}^2$$

Pour un risque $\alpha = 0.05$, la région critique conduisant au rejet de H_0 pour une loi du χ_1^2 est défini par : $[3,841, +\infty[$

Application numérique:

$$\chi^2 = \frac{(135 - 121.1)^2}{121.1} + \frac{(120 - 133.9)^2}{133.9} + \frac{(150 - 163.9)^2}{163.9} + \frac{(195 - 181.1)^2}{181.1} = 5.36$$

Au risque $\alpha = 0,05$, la valeur 5,36 appartient à la zone critique. On rejette alors H_0



Illustration graphique



- Graphiquement, nous pouvons aussi déduire l'existence de relation entre deux variables qualitatives en utilisant:

le diagramme en barre regroupé





Diagramme en mosaïque





3. Une variable quantitative vs qualitative




- Croiser une variable quantitative et une variable qualitative, c'est essayer de voir si les valeurs de la variable quantitative se **répartissent différemment** selon la catégorie d'appartenance de la variable qualitative.
- Pour étudier la relation entre une variable qualitative et une variable quantitative:
 - on utilise la boîte à moustache.
 - Un test statistique.

► Illustration graphique



- l'idéal est de commencer par une représentation graphique de type « boîte à moustache » pour chacune des sous-populations.
- on veut en général savoir si la distribution des valeurs de la variable quantitative est la même selon les modalités de la variable qualitative (sous-populations)





► Test de Statistique

Hypothèses du test:

H_0 : Les variables X et Y sont indépendantes.

H_1 : Il existe une liaison entre Les variables X et Y

il faut vérifier les hypothèses avant d'effectuer un test de Student:

- Distribution gaussienne.

- Égalité de la variance

sinon il faut faire un autre test comme celui de Wilcoxon.

Règle de décision:

Si la valeur de p-value est **inférieure** à 5%, alors on rejette H_0 .

Si la valeur de p-value est **supérieur** à 5%, alors on accepte H_0 .